

# Primeira avaliação (A1)

Disciplina: Inferência Estatística  
Professor: Luiz Max de Carvalho

20 de Setembro de 2021

- Por favor, entregue um único arquivo PDF;
- O tempo para realização da prova é de 4 (quatro) horas, mais vinte minutos para upload do documento para o e-class;
- Responda todas as questões sucintamente;
- Marque a resposta final claramente com um quadrado, círculo, ou figura geométrica de sua preferência;
- A prova vale 80 pontos; a pontuação restante é contada como bônus.
- Apenas tente resolver a questão bônus quando tiver resolvido todo o resto.

## Dicas

- Se  $X$  tem distribuição exponencial com parâmetro  $\lambda > 0$ , então, para  $x > 0$  as funções de densidade de probabilidade e densidade acumulada são, respectivamente,

$$f_X(x) = \lambda \exp(-\lambda x),$$
$$F_X(x) = 1 - \exp(-\lambda x).$$

- Se  $X$  tem distribuição Gama com parâmetros  $\alpha > 0$  e  $\beta > 0$  e f.d.p.,

$$f_X(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} \exp(-\beta x),$$

para  $x > 0$ , então  $W = 1/X$  tem distribuição Gama-inversa, com f.d.p.

$$f_W(w) = \frac{\beta^\alpha}{\Gamma(\alpha)} w^{-(\alpha+1)} \exp(-\beta/w),$$

para  $w > 0$ . Ademais,  $E[W] = \beta/(\alpha-1)$  e  $\text{Var}(W) = \beta^2/[(\alpha-1)^2(\alpha-2)]$ .

- Se  $X_i \sim \text{Gama}(\alpha_i, \beta)$ , com  $\alpha_i > 0$  para todo  $i$  e  $\beta > 0$ , então  $Y = \sum_{i=1}^n X_i$  tem distribuição Gama com parâmetros  $\alpha_y = \sum_{i=1}^n \alpha_i$  e  $\beta_y = \beta$ .
- Se  $X \sim \text{Gama}(\alpha, \beta)$ ,  $Y = cX$  tem distribuição  $\text{Gama}(\alpha, \beta/c)$  para  $c > 0$ .

## 1. Circling the square.

Um círculo  $C_r$  de raio  $r$  é inscrito em uma folha de papel quadrada com lado  $b$ . Suponha que desejamos estimar a área  $A$  deste círculo. Para tanto, vamos amostrar vetores aleatórios de uma distribuição uniforme definida sobre a folha de papel e, para estimar a área da circunferência, contar a proporção de vetores caindo dentro e fora de  $C_r$  e multiplicar esta proporção pela área total da folha de papel.

- a) (2,5 pontos) Mostre que se  $X$  e  $Y$  são variáveis aleatórias i.i.d. com distribuição Uniforme(0,  $b$ ), então  $(X, Y)$  possui função de densidade de probabilidade constante sobre  $(0, b) \times (0, b)$ ;
- b) (7,5 pontos) Você deixa cair grãos de milho sobre a folha e conta quantos deles caíram dentro do círculo e fora do círculo (porém na folha). Vamos supor que este mecanismo gera observações i.i.d. uniforme sobre  $(0, b)^2$ . Represente os grãos que caíram sobre a folha através de  $(X_1, Y_1), \dots, (X_n, Y_n)$  e defina  $Z_i = \mathbb{I}((X_i, Y_i) \in C_r)$ ,  $i = 1, \dots, n$  como uma variável indicadora que recebe valor 1 se o grão está dentro da circunferência. Suponha que depois de medir  $\mathbf{Z}$  você joga fora  $\mathbf{X}$  e  $\mathbf{Y}$ , isto é, guarda o milho no pote de novo para fazer pipoca mais tarde. Construa um modelo estatístico parametrizado pela área,  $A$ , da circunferência que reflete este experimento. Encontre uma estatística suficiente mínima para o parâmetro deste modelo.
- Dica:* desenhe um diagrama e considere as áreas envolvidas (evite avaliar integrais!);
- c) (5 pontos) Considere  $\delta_1(\mathbf{Z}) = b^2 \bar{Z}_n$ . Este é um estimador não enviesado da área do círculo?
- d) (5 pontos) Calcule o erro quadrático médio  $R(A, \delta_1)$  de  $\delta_1$  e discuta como ele se comporta em relação à quantidade de interesse. O que acontece com  $R(A, \delta_1)$  quando  $A$  cresce?

**Conceitos trabalhados:** Modelo estatístico, suficiência, viés, EQM.

**Nível de dificuldade:** fácil.

**Resolução:**<sup>1</sup> Para responder a) basta notar que  $X$  e  $Y$  i.i.d implica

$$f_{X,Y}(x, y) = f_X(x)f_Y(y) = \begin{cases} \frac{1}{b^2}, & x, y \in (0, b), \\ 0, & \text{caso contrário,} \end{cases}$$

que é constante em  $(0, b) \times (0, b)$ . Para responder b) temos que encontrar  $\eta = \Pr(Z_i = 1)$  e então nosso modelo estatístico será  $Z_i \sim \text{Bernoulli}(\eta(A))$ , isto é, a probabilidade de  $Z_i = 1$  depende de  $A$  de acordo com uma função conhecida da área  $A$ , que é a quantidade de interesse. Vamos mostrar duas maneiras de computar  $\eta$  com **forte** preferência pela maneira mais simples. Sabemos que para qualquer variável aleatória cuja distribuição tenha pdf  $f$ , vale

$$\Pr(X \in C) = \int_C f(x) dx.$$

<sup>1</sup>O título é um trocadilho (“Circle ‘in’ the square”) que faz referência ao famoso problema de construir um quadrado com a mesma área de um círculo usando apenas compasso e régua: [https://en.wikipedia.org/wiki/Squaring\\_the\\_circle](https://en.wikipedia.org/wiki/Squaring_the_circle).

Logo, concluimos que

$$\Pr(Z_i = 1) = \int_{C_r} f_{X,Y}(x,y) dx dy = \frac{\pi r^2}{b^2}.$$

isto é, a razão entre área do círculo e do quadrado. Desta forma,  $\eta(A) = A/b^2$ . Agora vamos discutir uma solução bem mais trabalhosa para o problema. Note que

$$\Pr(Z_i = 1) = \Pr((X_i, Y_i) \in C_r) = \Pr(X_i^2 + Y_i^2 \leq r^2).$$

Sem perda de generalidade, vamos centrar  $C_r$  em  $(b/2, b/2)$ . Se definirmos  $U = (X_i - b/2)^2$ ,  $V = (Y_i - b/2)^2$  e  $T = U + V$ , temos que

$$\Pr(Z_i = 1) = F_T(r^2).$$

Lembrando da fórmula para convolução (soma) de duas v.a.s independentes, temos

$$F_T(t) = \int_{-\infty}^{\infty} F_U(t-v) f_V(v) dv.$$

Para computar  $F_U$ , fazemos

$$\begin{aligned} \Pr(U \leq u) &= \Pr((X_i - b/2)^2 \leq u), \\ &= \Pr(|X_i - b/2| \leq \sqrt{u}) = 2F_X(\sqrt{u}), \\ &= 2\frac{\sqrt{u}}{b} \end{aligned}$$

o que também significa que  $f_V(v) = 1/\sqrt{v}$  porque  $U$  e  $V$  são i.i.d. Juntando tudo, temos

$$\begin{aligned} F_T(t) &= \int_0^{\frac{b^2}{4}} 2\frac{\sqrt{t-v}}{b\sqrt{v}} dv, \\ &= \Re \left( \frac{2}{b^2} \left\{ \frac{b\sqrt{4t-b^2} - 4t \arctan\left(\frac{\sqrt{4t-b^2}}{b}\right)}{4} + \frac{\pi t}{2} \right\} \right), \\ &= \frac{\pi t}{b^2}, \end{aligned}$$

onde  $\Re(a+bi) = a$  denota a parte real e  $\arctan(x) = y$  se  $\tan(y) = x$ . A última linha segue do fato de que  $\Re(\sqrt{4r^2-b^2}) = 0$  para  $r \in (0, b/2)$ , isto é, para os círculos que nos interessam aqui. Avaliar  $F_T(r^2)$  completa a computação necessária. **Eu avisei que era melhor evitar computar integrais!**

Vamos mostrar que a soma é suficiente mínima neste exemplo. Para encontrar uma estatística suficiente, vamos utilizar o teorema da fatorização<sup>2</sup>:

$$\begin{aligned} f_n(\mathbf{Z} \mid \eta(A)) &= \prod_{i=1}^n \eta(A)^{z_i} (1 - \eta(A))^{1-z_i}, \\ &= \eta(A)^S (1 - \eta(A))^{n-S}, \end{aligned}$$

---

<sup>2</sup>Também chamado de Teorema da Fatorização de Neyman-Fisher, ou NFFT na sigla em inglês.

com  $S = \sum_{i=1}^n z_i$ . Daí, vemos que podemos fatorar a densidade condicional conjunta em  $u(\eta(A)) = 1$  e  $v[S, \eta(A)] = \eta(A)^S (1 - \eta(A))^{n-S}$  e portanto  $S$  é suficiente para  $\eta(A)$ . Para mostrar que  $S$  é suficiente **mínima**, vamos considerar uma estatística suficiente  $T(\mathbf{Z})$  de modo que possamos escrever

$$f_n(\mathbf{Z} \mid \eta(A)) = g[T, \eta(A)]h(\eta(A)).$$

Agora, tome  $A_1 \neq A_2$  e faça

$$\begin{aligned} \frac{\eta(A_1)^S (1 - \eta(A_1))^{n-S}}{\eta(A_2)^S (1 - \eta(A_2))^{n-S}} &= \frac{g[T, \eta(A_1)]h(\eta(A_1))}{g[T, \eta(A_2)]h(\eta(A_2))}, \\ \left( \frac{\eta(A_1) [1 - \eta(A_2)]}{\eta(A_2) [1 - \eta(A_1)]} \right)^S \left( \frac{(1 - \eta(A_1))}{(1 - \eta(A_2))} \right)^n &= \frac{g[T, \eta(A_1)]h(\eta(A_1))}{g[T, \eta(A_2)]h(\eta(A_2))}, \end{aligned}$$

de onde obtemos

$$S = f(T) = \frac{\log \left( \frac{g[T, \eta(A_1)]h(\eta(A_1))}{g[T, \eta(A_2)]h(\eta(A_2))} \right) - n \log \left( \frac{(1 - \eta(A_1))}{(1 - \eta(A_2))} \right)}{\log \left( \frac{\eta(A_1) [1 - \eta(A_2)]}{\eta(A_2) [1 - \eta(A_1)]} \right)},$$

e, com isso, mostramos que  $S = f(T(\mathbf{Z}))$  para toda estatística suficiente  $T$ , como queríamos.

Outra forma de mostrar que  $S$  é suficiente mínima é mostrar que  $S$  é uma função bijetiva do EMV  $\hat{p}$  de  $p := \eta(A)$ . Isso implica em  $\hat{p}$  ser suficiente, o que, pelo Teorema 7.8.3 de DeGroot (Observação 10 dos slides), significa que  $\hat{p}$  é suficiente mínimo e, assim,  $S$  também será suficiente mínima, por ser uma função bijetiva de uma estatística suficiente mínima. Sendo assim, vamos encontrar  $\hat{p}$ . Maximizar  $f_n(\mathbf{Z} \mid p)$  é equivalente a maximizar

$$G(p) := \log f_n(\mathbf{Z} \mid p) = S \log p + (n - S) \log(1 - p).$$

Derivando, obtemos

$$G'(p) = \frac{S}{p} + \frac{S - n}{1 - p}$$

e

$$G''(p) = -\frac{S}{p^2} + \frac{S - n}{(1 - p)^2}.$$

Como  $S \leq n$ , temos  $G''(p) \leq 0$  para todo  $p$ . Portanto,  $\hat{p}$  é a solução de  $G'(p) = 0$ , que podemos, sem muito esforço, identificar como sendo  $S/n$ . Dessa forma, temos  $S = n\hat{p}$  e está mostrada a suficiência mínima de  $S$ . Agora, vamos trabalhar em c). Escrever  $Z_1, \dots, Z_n \sim \text{Bernoulli}(\eta(A))$  implica

$$E[\delta_1] = \frac{b^2}{n} E \left[ \sum_{i=1}^n Z_i \right] = \frac{b^2}{n} n E[Z_1] = b^2 \eta(A) = \pi r^2.$$

Concluimos portanto que  $\delta_1$  é **não-viesado**.

De c) sabemos que

$$\begin{aligned}
 R(A, \delta_1) &= \text{Var}(\delta_1(\mathbf{Z})), \\
 &= \frac{b^4}{n^2} \text{Var}(S) = \frac{b^4 n}{n^2} \text{Var}(Z_1), \\
 &= \frac{b^4}{n} \left( \frac{A}{b^2} \left( 1 - \frac{A}{b^2} \right) \right), \\
 &= \frac{A(b^2 - A)}{n},
 \end{aligned}$$

o que responde d). Note que  $\text{Var}(\delta_1)$  é uma função côncava e atinge seu máximo em  $A = b^2/2$ , que é o ponto médio da amplitude de  $A$ ,  $(0, b^2/4)$ . A Figura 1 mostra um esboço de  $R(A, \delta_1) = \text{Var}(\delta_1)$ . ■




Figura 1: **Erro quadrático médio do estimador  $\delta_1$ .** Mostramos a curva para  $n = 10, 30$  e  $100$  com  $b = 1$ . Note que o máximo é atingido em  $(b^2/4 - 0)/2 = b^2/2$ .

## 2. The shinning.

Suponha que você é a pessoa responsável pelo controle estatístico de qualidade na fábrica de lâmpadas *LuminaEu*. Seu chefe, Astolfo, lhe envia uma planilha com os valores  $X_1, X_2, \dots, X_n$  dos tempos de falha de  $n$  lâmpadas (em dias). Você lê no manual da empresa que um modelo exponencial i.i.d. com parâmetro  $\theta$  é apropriado para análise.

- (5 pontos) Mostre que o estimador de momentos para  $\theta$  coincide com o EMV neste caso;
- (10 pontos) Discuta se o estimador do item anterior é eficiente para amostras finitas. O que acontece assintoticamente?
- (5 pontos) Conhecendo Astolfo, no entanto, você sabe que ele não saberá interpretar quaisquer estimativas diretas da taxa  $\theta$ , então decide considerar a probabilidade de excedência<sup>3</sup>  $\alpha := \Pr(X_1 > c)$  para um certo  $c > 0$ . Encontre um estimador de máxima verossimilhança para  $\alpha$ ;

**Conceitos trabalhados:** Método dos momentos, EMV, reparametrização, invariância, eficiência.

**Nível de dificuldade:** fácil.

**Resolução:** Sabendo que  $E[X_1] = 1/\theta$ , o estimador de momentos pode ser obtido escrevendo  $\bar{x}_n = 1/\theta$  o que nos leva a  $\hat{\theta}_{MM} = n/S$ , com  $S = \sum_{i=1}^n X_i$ . Para o encontrar o EMV, escrevemos

$$f_n(\mathbf{X} \mid \theta) = \theta^n \exp(-S\theta).$$

Tomando o log e diferenciando, temos

$$\lambda'_n(\mathbf{X} \mid \theta) = \frac{n}{\theta} - S, \quad (1)$$

$$\lambda''_n(\mathbf{X} \mid \theta) = -\frac{n}{\theta^2}, \quad (2)$$

que nos informam que o problema de otimização é côncavo, o que garante que nosso velho conhecido  $\hat{\theta}_{EMV} = n/S = 1/\bar{x}_n$  é o único ponto de máximo e o nosso EMV para  $\theta$ . Isso mostra que os estimadores coincidem.

Para entender se  $\delta(X) = n/S$  é eficiente, convém entender primeiro se é viesado. Das dicas podemos deduzir que  $\delta$  tem distribuição Gamma inversa com parâmetros  $\alpha_\delta = n$  e  $\beta_\delta = n\theta$ , o que nos leva à conclusão de que  $E_\theta[\delta] = n/(n-1)\theta$  e portanto  $\text{vies}(\delta) = -\theta/(n-1)$ . Das dicas sabemos também que

$$\text{Var}_\theta(\delta) = \frac{n^2\theta^2}{(n-1)^2(n-2)}.$$

Agora vamos verificar se  $\delta$  atinge a cota inferior de Crámer-Rao:

$$\text{Var}_\theta(\delta) \geq \frac{[m'(\theta)]^2}{nI(\theta)},$$

---

<sup>3</sup>Em inglês, *exceedance probability*.

onde  $m(\theta) := E_\theta[\delta]$  e  $I(\theta)$  é a informação de Fisher. Dos cálculos acima, sabemos que  $[m'(\theta)]^2 = n^2/(n-1)^2$ . Para computar  $I(\theta)$  vamos nos aproveitar da identidade  $I(\theta) = \text{Var}_\theta(\lambda'(x | \theta))$ :

$$I(\theta) = \text{Var}_\theta\left(\frac{1}{\theta} - x\right) = \text{Var}_\theta\left(\frac{1}{\theta}\right) + \text{Var}_\theta(-x) = 0 + \frac{1}{\theta^2}.$$

Juntando tudo, temos

$$\text{Var}_\theta(\delta) \geq \frac{n\theta^2}{(n-1)^2} = V_{\text{op}},$$

o que mostra que  $\delta$  está longe de ser eficiente para amostras finitas. Com efeito,  $\text{Var}_\theta(\delta)/V_{\text{op}} = n/(n-2)$ , o que indica que o EMV e o EMM são assintoticamente eficientes.

Das dicas, sabemos que  $\alpha = 1 - F_X(c) = \exp(-\theta c)$ , o que nos leva a

$$\theta = -\log(\alpha)/c. \quad (3)$$

Para responder c) e encontrar o EMV de  $\alpha$ , temos dois caminhos: (i) lembrar da invariância do EMV, substituir o estimador do item anterior em (3) ou; (ii) reescrever a verossimilhança de acordo com o novo parâmetro (procedimento chamado de *reparametrização*) e maximizar esta nova função. Como você deve estar adivinhando, aqui vamos fazer as duas coisas. Fazendo a substituição, temos  $\hat{\alpha} = \exp(-\hat{\theta}c) = \exp(-nc/S)$  e, para o caminho (ii):

$$\begin{aligned} f_n(\mathbf{X} | \alpha) &= [-\log(\alpha)/c]^n \exp(S \log(\alpha)/c), \\ &\propto [-\log(\alpha)]^n \exp(S \log(\alpha)/c). \end{aligned}$$

Fazendo o procedimento usual, temos

$$\lambda'_n(\mathbf{X} | \alpha) = \frac{n}{\alpha \log(\alpha)} + \frac{S}{c\alpha}, \quad (4)$$

$$\lambda''_n(\mathbf{X} | \alpha) = -\frac{n}{\alpha^2 \log(\alpha)} - \frac{n}{\alpha^2 \log^2(\alpha)} - \frac{S}{c\alpha^2}. \quad (5)$$

Para começar, vemos que atacar o problema diretamente foi uma má ideia: as equações são mais difíceis de resolver e de verificar. Não obstante, podemos resolver (4) e encontrar...  $\hat{\alpha} = \exp(-nc/S)$ , para surpresa de 0 pessoas! Isso conclui c). ■

### 3. Cool and normal!

Suponha que você é a pessoa responsável por analisar a concentração de ácido em pedaços de queijo vindos da famosa fábrica de frios francesa *J'skeci*. Assumindo uma distribuição normal para as concentrações em  $n$  medições independentes de  $n$  pedaços distintos, você precisa descobrir a média  $\mu$  e a variância  $v$  desta distribuição.

a) (5 pontos) Considere a priori imprópria

$$\xi(\mu, v) \propto 1/v \quad (6)$$

Mostre que a posteriori  $\xi(\mu, v | \mathbf{x})$  é própria;

*Dica:* Procure com atenção o núcleo de distribuições conhecidas.

- b) (7,5 pontos) Exiba o estimador de Bayes sob perda quadrática para  $v$  e o estimador de Bayes sob perda absoluta para  $\mu$  e discuta se esses estimadores são viesados;
- c) (5 pontos) Encontre uma priori conjugada para  $(\mu, v)$ ;
- d) (2,5 pontos) Mostre que a priori em (6) pode ser vista como um limite particular (dos hiperparâmetros) da priori conjugada do item anterior.

**Conceitos trabalhados:** Bayes, propriedade, conjugação

**Nível de dificuldade:** médio.

**Resolução:** Para começar, vamos escrever a verossimilhança:

$$f_n(\mathbf{x} \mid \mu, v) = \left[ \frac{1}{\sqrt{2\pi v}} \right]^n \exp \left( -\frac{1}{2v} \sum_{i=1}^n (x_i - \mu)^2 \right).$$

Descartando termos que não dependem dos parâmetros de interesse e utilizando a igualdade  $\sum_{i=1}^n (x_i - \mu)^2 = \sum_{i=1}^n (x_i - \bar{x}_n)^2 + n(\mu - \bar{x}_n)^2 = s_n^2 + n(\mu - \bar{x}_n)^2$ , temos

$$\begin{aligned} f_n(\mathbf{x} \mid \mu, v) &\propto v^{-n/2} \exp \left( -\frac{1}{2v} \{s_n^2 + n(\mu - \bar{x}_n)^2\} \right), \\ &\propto \exp \left( -\frac{n(\mu - \bar{x}_n)^2}{2v} \right) v^{-n/2} \exp \left( -\frac{s_n^2}{2v} \right). \end{aligned}$$

Daí, temos a posteriori

$$\begin{aligned} \xi(\mu, v \mid \mathbf{x}) &\propto f_n(\mathbf{x} \mid \mu, v) \xi(\mu, v), \\ &\propto \underbrace{\exp \left( -\frac{n(\mu - \bar{x}_n)^2}{2v} \right)}_{\text{Normal}(\bar{x}_n, \frac{v}{n})} \underbrace{v^{-n/2-1} \exp \left( -\frac{s_n^2}{2v} \right)}_{\text{Gama-Inversa}(\frac{n}{2}, \frac{s_n^2}{2})}, \\ &= p_1(\mu \mid \mathbf{x}, v) p_2(v \mid \mathbf{x}). \end{aligned} \quad (7)$$

Vemos então que a posteriori se fatora em uma posteriori para  $\mu$  condicional a  $v$  e aos dados, e uma posteriori marginal (em relação a  $\mu$ ) para  $v$ . Com isso, podemos responder b): Para  $v$  queremos a média *a posteriori*, que é o estimador de Bayes sob perda quadrática. Usando as dicas, sabemos que  $E_{p_2}[v] = (s_n^2/2)/((n-2)/2) = s_n^2/(n-2)$ . Já o estimador solicitado para  $\mu$  é a mediana *a posteriori* de acordo com  $p_1$ , o que é simplesmente  $\bar{x}_n$ . Note que este estimador independe do valor de  $v$ . Agora podemos dizer que o estimador para  $\mu$  é não-viesado, já que  $E[\bar{X}_n] = \mu$ , e que o estimador para  $v$  é viesado, já que o estimador de  $v$  não-viesado da forma  $\delta_c(\mathbf{X}) = c \sum_{i=1}^n (X_i - \bar{X}_n)^2$  tem  $c = 1/(n-1)$ , como visto em aula.

Para responder c) vamos notar que precisamos encontrar  $\tilde{\xi} : (-\infty, \infty) \times (0, \infty) \rightarrow (0, \infty) \in \mathcal{F}$  de modo que

$$\exp \left( -\frac{n(\mu - \bar{x}_n)^2}{2v} \right) v^{-n/2} \exp \left( -\frac{s_n^2}{2v} \right) \tilde{\xi}(\mu, v) \in \mathcal{F}.$$

As derivações acima sugerem uma estrutura condicional para  $\tilde{\xi}$  da mesma forma daquela em (7): se fizermos  $\tilde{\xi}(\mu, v) = \pi_1(\mu \mid v) \pi_2(v)$ , podemos escrever:

$$\tilde{\xi}(\mu, v \mid \mathbf{x}) \propto \exp \left( -\frac{n(\mu - \bar{x}_n)^2}{2v} \right) \pi_1(\mu \mid v) \cdot v^{-n/2} \exp \left( -\frac{s_n^2}{2v} \right) \pi_2(v) \in \mathcal{F},$$



o que nos sugere o sistema de equações funcionais

$$\begin{aligned}\exp\left(-\frac{n(\mu - \bar{x}_n)^2}{2v}\right) \pi_1(\mu | v) &= \text{Normal}(m, \tau), \\ v^{-n/2} \exp\left(-\frac{s_n^2}{2v}\right) \pi_2(v) &= \text{Gama-inversa}(\alpha', \beta').\end{aligned}$$

Para resolver a primeira equação, lembramos que para  $v$  fixa, podemos escrever  $\pi_1(\mu, v; m, \lambda) = \text{Normal}(m, v/\lambda)$  e, completando o quadrado (duas vezes) vemos que a posteriori resultante continua na família normal (condicional a  $v$ ). Também podemos ver que  $\pi_2(v; \alpha_0, \beta_0) = \text{Gama-inversa}(\alpha_0, \beta_0)$  leva a uma posteriori marginal para  $v$  que permanece na família Gama-inversa, o que conclui o nosso argumento.

No que toca à questão d), vamos escrever a densidade conjunta *a priori*:

$$\tilde{\xi}(\mu, v) = \frac{\beta_0^{\alpha_0}}{\Gamma(\alpha_0)} v^{-\alpha_0-1} \exp(-\beta_0 v) \frac{1}{\sqrt{2\pi v}} \exp\left(-\frac{\lambda(\mu - m)^2}{2v}\right).$$

Para obter  $\tilde{\xi}(\mu, v) \propto v^{-1}$ , podemos tomar  $\beta_0 \rightarrow \infty$ ,  $\alpha_0 \rightarrow 0$  pelo lado da Gama-inversa e  $\lambda \rightarrow \infty$  pelo lado da normal. Desta forma, vemos que, pelo menos neste caso, uma priori imprópria pode ser vista como um limite particular de prioris próprias. ■

## 4. Get your ducks in a row.

Pato Donald, Huguinho, Zezinho e Luisinho estão estudando Inferência Estatística para trabalhar no *hedge fund* do Tio Patinhas. O problema em questão é a estimação do parâmetro  $\theta$  de uma distribuição uniforme em  $(\theta/2, 3\theta/2)$  a partir de uma amostra aleatória  $X_1, X_2, \dots, X_n$ . Cada um propôs um estimador diferente para  $\theta$  e seu trabalho é ajudar o Tio Patinhas a ordenar esses estimadores em ordem de qualidade.

Sejam  $M := \max(X_1, X_2, \dots, X_n)$  e  $m := \min(X_1, X_2, \dots, X_n)$ .

Os estimadores escolhidos foram

1.  $\delta_D(\mathbf{X}) = X_1$ , para o Pato Donald;
2.  $\delta_H(\mathbf{X}) = m$ , para Huguinho;
3.  $\delta_Z(\mathbf{X}) = M$ , para Zezinho;
4.  $\delta_L(\mathbf{X}) = (M + m)/2$ , para Luisinho;

Para lhe ajudar na tarefa de julgar estes estimadores, Tio Patinhas enviou o

seguinte conjunto de fatos úteis: para  $X_1, X_2, \dots, X_n \sim \text{Uniforme}(a, b)$ , temos

$$\begin{aligned} E[X_1] &= \frac{a+b}{2}, \\ \text{Var}(X_1) &= \frac{(b-a)^2}{12}, \\ E[m] &= a + \frac{1}{n+1}(b-a), \\ E[M] &= b - \frac{1}{n+1}(b-a), \\ \text{Var}(m) &= \text{Var}(M) = \frac{n}{(n+1)^2(n+2)}(b-a)^2, \\ \text{Cov}(m, M) &= \frac{(b-a)^2}{(n+1)^2(n+2)}, \\ \text{Corr}(m, M) &= \frac{1}{n}. \end{aligned}$$

Os patos ainda não sabem Inferência Estatística muito bem, portanto tenha paciência com eles.

- a) (2,5 pontos) Os estimadores de Huguinho e Zezinho são viesados. Mostre aos patinhos como construir versões não-viesadas,  $\delta_{UH}(\mathbf{X})$  e  $\delta_{UZ}(\mathbf{X})$  ;
- b) (2,5 pontos) Discuta se algum dos estimadores do item anterior é inadmissível;
- c) (2,5 pontos) Mostre que  $\mathbf{T} = (m, M)$  é suficiente conjunta para  $\theta$ ;
- d) (7,5 pontos) Mostre que  $\delta_L(\mathbf{X}) = E[\delta_D(\mathbf{X}) | \mathbf{T}]$ , isto é, que o estimador de Luisinho é o melhoramento de Rao-Blackwell do estimador do Pato Donald;
- e) (5 pontos) Ordene os estimadores  $\delta_D(\mathbf{X})$ ,  $\delta_{UH}(\mathbf{X})$ ,  $\delta_{UZ}(\mathbf{X})$  e  $\delta_L(\mathbf{X})$  em termos de erro quadrático médio. Quem propôs o melhor estimador?<sup>4</sup>

**Conceitos trabalhados:** Rao-Blackwell, viés, EQM, admissibilidade.

**Nível de dificuldade:** médio.

**Resolução:** Para começar, vamos nos dar conta de que

$$\begin{aligned} E_\theta[\delta_H(\mathbf{X})] &= \frac{1}{2}\theta + \frac{1}{n+1}\theta = \frac{n+3}{2(n+1)}\theta = k_H\theta, \\ E_\theta[\delta_Z(\mathbf{X})] &= \frac{3}{2}\theta - \frac{1}{n+1}\theta = \frac{3n+1}{2(n+1)}\theta = k_Z\theta, \end{aligned}$$

o que imediatamente sugere

$$\begin{aligned} \delta_{UH}(\mathbf{X}) &= \frac{1}{k_H}\delta_H(\mathbf{X}), \\ \delta_{UZ}(\mathbf{X}) &= \frac{1}{k_Z}\delta_Z(\mathbf{X}), \end{aligned}$$

---

<sup>4</sup>No caso de Huguinho e Zezinho, com a sua ajuda.

como soluções de a). Para reponder b), vamos lembrar que os estimadores são não-viesados e desta forma os EQMs são dados apenas pelas variâncias dos estimadores. Portanto:

$$\begin{aligned} R(\theta, \delta_{UH}) &= \text{Var}(\delta_{UH}(\mathbf{X})) = \frac{1}{k_H^2} \text{Var}(\delta_H(\mathbf{X})) = \frac{4(n+1)^2}{(n+3)^2} \text{Var}(\delta_H(\mathbf{X})), \\ R(\theta, \delta_{UZ}) &= \text{Var}(\delta_{UZ}(\mathbf{X})) = \frac{1}{k_Z^2} \text{Var}(\delta_Z(\mathbf{X})) = \frac{4(n+1)^2}{(3n+1)^2} \text{Var}(\delta_H(\mathbf{X})), \end{aligned}$$

onde a última igualdade da segunda linha vem do fato de que  $m$  e  $M$  tem a mesma variância. Com isso vemos que o estimador de Zezinho domina uniformemente o estimador de Huguinho, que é inadmissível, portanto. Uma observação interessante, então, é de que, no que toca à tarefa de estimar  $\theta$ , o máximo da amostra é estritamente mais informativo sobre o parâmetro que o mínimo. Parte da questão c) foi trabalhada em aula. Em particular, podemos escrever a verossimilhança como

$$f_n(\mathbf{X} \mid \theta) = \begin{cases} \frac{\mathbb{I}(m/2 < \theta) \mathbb{I}(2M/3 < \theta)}{\theta^n}, & 0 \leq x \leq \theta, \\ 0, & \text{caso contrário,} \end{cases}$$

o que mostra que  $\mathbf{T} = (m, M)$  é suficiente<sup>5</sup>, pelo Teorema da Fatorização. A solução de d) passa por lembrar bem o que é o mecanismo de Rao-Blackwell para melhoramento de estimadores: dado um estimador  $\delta$  de  $g(\theta)$ , e uma estatística suficiente  $T$  para  $g(\theta)$ , podemos sempre construir

$$\delta_0 := E_\theta[\delta \mid T],$$

que domina  $\delta$  em termos de EQM. Com as informações das dicas da questão e do item c), fica claro que estamos procurando  $E_\theta[\delta_D(\mathbf{X}) \mid m, M]$ . Notando que

$$f_1(x_1 \mid m, M) = \begin{cases} \frac{1}{M-m}, & m \leq x_1 \leq M, \\ 0, & \text{caso contrário,} \end{cases}$$

isto é que  $X_1 \mid m, M \sim \text{Uniforme}(m, M)$ , obtemos

$$\begin{aligned} E_\theta[X_1 \mid m, M] &= E_\theta[\delta_D(\mathbf{X}) \mid \delta_H(\mathbf{X}), \delta_Z(\mathbf{X})], \\ &= \frac{\delta_Z(\mathbf{X}) + \delta_H(\mathbf{X})}{2}, \\ &= \delta_L(\mathbf{X}), \end{aligned}$$

como queríamos demonstrar. Para finalizar a questão e responder e), precisamos computar o EQM dos estimadores do Pato Donald e de Luisinho. Para o primeiro, temos:

$$\begin{aligned} R(\theta, \delta_D(\mathbf{X})) &= \text{Var}(X_1) + [E[X_1] - \theta]^2, \\ &= \frac{\theta^2}{12} + 0 = \frac{1}{12}\theta^2. \end{aligned}$$

---

<sup>5</sup>Além disso,  $\mathbf{T}' = (m/2, 2M/3)$  também é suficiente para  $\theta$ .

Já para o estimador de Luisinho, temos

$$\begin{aligned} E[\delta_L(\mathbf{X})] &= \frac{E[m] + E[M]}{2} = \frac{(4n+4)\theta}{4(n+1)} = \theta, \\ \text{Var}(\delta_L(\mathbf{X})) &= \frac{\text{Var}(m) + \text{Var}(M) + 2\text{Cov}(m, M)}{4}, \\ &= \frac{\text{Var}(M) + \text{Cov}(m, M)}{2}, \\ &= \frac{\theta^2}{2(n+1)(n+2)}. \end{aligned}$$

Com isso, podemos computar

$$R(\theta, \delta_L(\mathbf{X})) = \frac{\theta^2}{2(n+1)(n+2)}.$$

Agora estamos preparados para construir a nossa ordenação:

$$\begin{aligned} R(\theta, \delta_D(\mathbf{X})) &= \frac{1}{12}\theta^2, \\ R(\theta, \delta_{UH}(\mathbf{X})) &= \frac{4n}{(n+3)^2(n+2)}\theta^2, \\ R(\theta, \delta_{UZ}(\mathbf{X})) &= \frac{4n}{(3n+1)^2(n+2)}\theta^2, \\ R(\theta, \delta_L(\mathbf{X})) &= \frac{1}{2(n+1)(n+2)}\theta^2. \end{aligned}$$

De modo que **Zezinho** é o vencedor, com o estimador com menor EQM. Isso se deve em parte ao fato de que Zezinho utilizou uma estatística suficiente. Luisinho até foi esperto e usou Rao-Blackwell, mas como o estimador original (do Pato Donald) não era uma estatística suficiente, acabou conseguindo um estimador ruim. A Figura 2 mostra a distribuição dos estimadores considerados aqui. ■

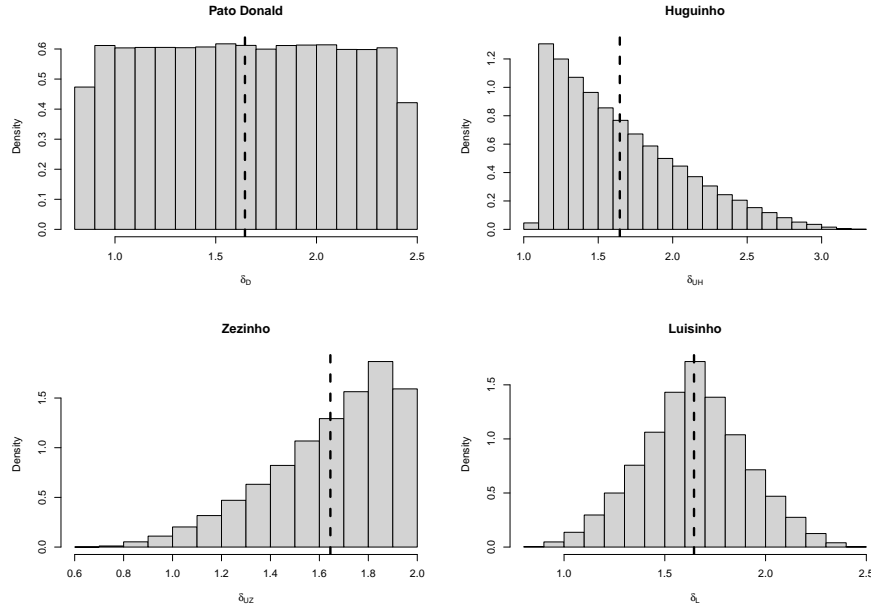


Figura 2: **Distribuição dos estimadores considerados pelos patos.** Mostramos a distribuição de cada estimador com  $\theta = \pi^2/6$ ,  $n = 3$  e  $M = 10^5$  realizações.

## 5. Questão bônus: Boss is boss, ain't it, dad?

Considere mais uma vez o problema da questão 4. Desta vez, Tio Patinhas resolveu propor o próprio estimador, e quer mostrar que esse estimador pode ser melhor que qualquer um dos propostos anteriormente. Para isso, propõe utilizar um estimador da forma

$$\delta_P(\mathbf{X}) = (1 - \alpha)\delta_{UH}(\mathbf{X}) + \alpha\delta_{UZ}(\mathbf{X}),$$

com  $\alpha \in (0, 1)$ .

- a) (10 pontos) Mostre que  $\delta_P$  é não-viesado e compute seu erro quadrático médio;

*Dica:* Lembre-se de que para  $a, b \in \mathbb{R}$ ,

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y).$$

- b) (10 pontos) Encontre  $\alpha_{op}$  que faz com que  $\delta_P$  tenha variância mínima. O estimador  $\delta_P^{op}(\mathbf{X}) = (1 - \alpha_{op})\delta_{UH}(\mathbf{X}) + \alpha_{op}\delta_{UZ}(\mathbf{X})$  domina todos aqueles derivados na questão 4? Justifique.

**Conceitos trabalhados:** variância mínima, combinação convexa de estimadores não-viesados.

**Nível de dificuldade:** médio.

**Resolução:** Começamos mostrando que

$$\begin{aligned} E[\delta_P(\mathbf{X})] &= E[(1 - \alpha)\delta_{UH} + \alpha\delta_{UZ}], \\ &= (1 - \alpha)E[\delta_{UH}] + \alpha E[\delta_{UZ}], \\ &= (1 - \alpha)\theta + \alpha\theta = \theta. \end{aligned}$$

Portanto,

$$\begin{aligned} R_\alpha(\theta, \delta_P(\mathbf{X})) &= \text{Var}((1 - \alpha)\delta_{UH} + \alpha\delta_{UZ}), \\ &= \text{Var}\left(\frac{(1 - \alpha)}{k_H}\delta_H + \frac{\alpha}{k_Z}\delta_Z\right), \\ &= \frac{(1 - \alpha)^2}{k_H^2} \text{Var}(m) + \frac{\alpha^2}{k_Z^2} \text{Var}(M) + 2\frac{\alpha(1 - \alpha)}{k_H k_Z} \text{Cov}(m, M), \\ &= \gamma \left( \frac{(1 - \alpha)^2 n}{k_H^2} + \frac{\alpha^2 n}{k_Z^2} + 2\frac{\alpha(1 - \alpha)}{k_H k_Z} \right), \end{aligned}$$

onde  $\gamma = \text{Cov}(m, M) = \frac{\theta^2}{(n+1)^2(n+2)}$ .

Para reponder b), vamos minimizar  $R_\alpha(\theta, \delta_P(\mathbf{X}))$  com respeito a  $\alpha$ :

$$\frac{d}{d\alpha} R_\alpha(\theta, \delta_P(\mathbf{X})) = 2\gamma \left( \frac{((k_Z^2 + k_H^2)n - 2k_H k_Z)\alpha - k_Z^2 n + k_H k_Z}{k_H^2 k_Z^2} \right), \quad (8)$$

Igualando (8) a zero, obtemos

$$\begin{aligned} \alpha_{\text{op}} &= \frac{k_Z^2 n - k_H k_Z}{(k_Z^2 + k_H^2)n - 2k_H k_Z}, \\ &= \frac{9n + 3}{10n + 6}. \end{aligned}$$

Com isso, concluímos que o estimador do Tio Patinhas é melhor que os outros, finalizando a questão. Como um extra, podemos calcular, depois de alguma álgebra,

$$R_\alpha(\theta, \delta_P(\mathbf{X})) = \frac{2}{(5n + 3)(n + 2)} \theta^2.$$

É importante notar que a melhoria não é escandalosa. Por exemplo, para  $\theta = \pi^2/6$ ,  $n = 3$ ,  $R_\alpha(\theta, \delta_{UZ}(\mathbf{X})) = 1.22 \times 10^{-3}$ , enquanto  $R_\alpha(\theta, \delta_P(\mathbf{X})) = 1.10 \times 10^{-3}$ .